ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

SUBJECT: SYNTHESIS PROJECT REPORT

A HAND GESTURE RECOGNITION SYSTEM BASED IMAGE FOR HUMAN-COMPUTER INTERACTION

Thành Viên :
Đặng Châu Anh 2310063
Bành Phú Hội 2311111

GVHD:
Nguyễn Đức Dũng

TP. HCM, 2025-2026

Mục lục

1 Abstract **2**

2 Introduction **3**
2.1 Nhận diện cử chỉ tay dựa trên đặc trưng 4
2.2 Nhận diện cử chỉ tay dựa trên học sâu 4

3 Mô hình nhận diện cử chỉ tay dựa trên học sâu **6**
3.1 Một số mạng CNN nâng cao 6
3.2 Trade-off giữa độ sâu của mạng và hiệu suất tính toán 7

4 Dataset **8**

5 Huấn luyện và đánh giá mô hình **9**
5.1 Tiền xử lý dữ liệu 9
5.2 Huấn luyện mô hình 10
5.3 Đánh giá mô hình 11
5.4 Kết quả thực nghiệm 11

6 Discussion **14**
6.1 So sánh với các nghiên cứu trước đây 14
6.2 Đánh giá ưu điểm và hạn chế của mô hình 14
6.3 Khả năng ứng dụng thực tiễn 14

Chương 1

Abstract

Nhận dạng cử chỉ tay (Hand Gesture Recognition – HGR) đóng vai trò quan trọng trong tương tác người–máy, cho phép giao tiếp trực quan và tự nhiên mà không cần tiếp xúc vật lý. Báo cáo này trình bày một hệ thống nhận dạng cử chỉ tay dựa trên mạng nơ–ron sâu, được thiết kế nhằm trích xuất các đặc trưng phân biệt một cách hiệu quả trong khi vẫn duy trì độ phức tạp tính toán thấp. Bài toán được huấn luyện và đánh giá trên tập dữ liệu có sẵn Hand Keypoints Dataset do Ultralytics cung cấp.

Hệ thống được xây dựng theo phương pháp học sâu dựa trên ảnh (image–based learning), trong đó các đặc trưng cử chỉ tay được mô hình hóa bởi mạng nơ–ron tích chập (CNN) với kiến trúc ResNet–18. Mô hình tự động học các đặc trưng trực tiếp từ dữ liệu ảnh đầu vào, thay vì sử dụng các đặc trưng thủ công được thiết kế sẵn.

Kết quả thực nghiệm cho thấy mô hình ResNet–18 đề xuất đạt được độ chính xác nhận dạng cao đồng thời duy trì tốc độ suy luận hiệu quả, phù hợp cho các ứng dụng thời gian thực. Ngoài ra, ResNet–18 thể hiện sự cân bằng tốt giữa độ chính xác và chi phí tính toán so với các kiến trúc mạng sâu hơn. Báo cáo này chứng minh hiệu quả của học tập dư thừa (residual learning) trong bài toán nhận dạng cử chỉ tay, đồng thời cho thấy tiềm năng ứng dụng trong các hệ thống tương tác người–máy, môi trường thông minh và công nghệ hỗ trợ.

Keywords: Hand Gesture Recognition, HGR, ResNet–18, Convolutional Neural Network, Image–based Learning

Chương 2

Introduction

Bài toán nhận diện cử chỉ tay có nhiều ứng dụng thực tiễn quan trọng trong các hệ thống HCI. Thông qua việc sử dụng camera và các mô hình học sâu, hệ thống có thể hiểu và diễn giải các cử chỉ tay của người dùng để điều khiển thiết bị mà không cần tiếp xúc vật lý. Ứng dụng tiêu biểu bao gồm điều khiển thiết bị thông minh trong nhà (bật/tắt đèn, điều chỉnh âm lượng, chuyển kênh), giao diện tương tác cho robot và hệ thống thực tế ảo/tăng cường (VR/AR), hỗ trợ người khuyết tật hoặc người khiếm thính trong giao tiếp, cũng như điều khiển an toàn trong môi trường công nghiệp hoặc y tế nơi việc chạm tay vào thiết bị là không thuận tiện. Nhờ khả năng hoạt động theo thời gian thực và tính linh hoạt cao, nhận diện cử chỉ tay góp phần nâng cao trải nghiệm người dùng, tăng mức độ tự nhiên của tương tác và mở ra nhiều hướng ứng dụng trong các hệ thống thông minh [11, 12, 13].

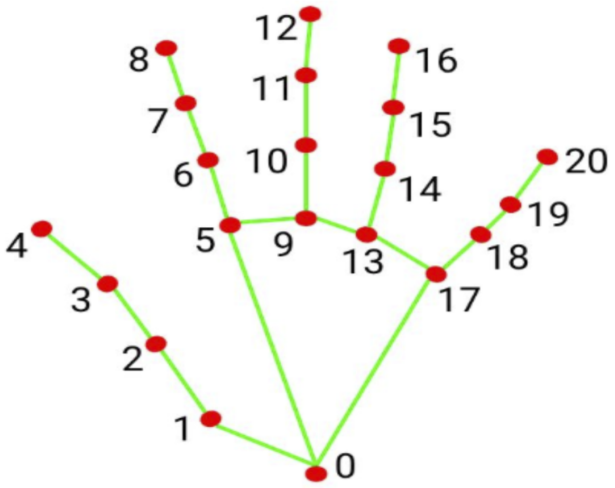

Hình 2.1: 21 điểm Keypoint

Trong bài toán nhận dạng cử chỉ tay, mỗi mẫu dữ liệu ảnh được gán nhãn đồng thời theo hai mức thông tin là vùng quan tâm (bounding box) và các điểm mốc hình học (keypoints). Bounding box được sử dụng để xác định và khoanh vùng vị trí bàn tay trong ảnh đầu vào, giúp mô hình tập trung vào khu vực chứa đối tượng cần nhận dạng và loại bỏ nhiễu từ nền xung quanh. Bên trong mỗi bounding box, bàn tay được biểu diễn chi tiết thông qua một tập hợp các keypoints tương ứng với các khớp và đầu ngón tay, thường bao gồm 21 điểm mốc mô tả đầy đủ cấu trúc hình học của bàn tay. Các keypoints này phản ánh vị trí không gian và mối quan hệ hình học giữa các bộ phận của bàn tay, cho phép mô hình học được hình dạng, tư thế và cấu hình ngón tay một cách chính xác. Việc kết hợp thông tin bounding box và keypoints không chỉ nâng cao độ chính xác trong việc định vị bàn tay mà còn cải thiện hiệu quả trích xuất đặc trưng phục vụ cho bài toán nhận dạng cử chỉ tay dựa trên ảnh.

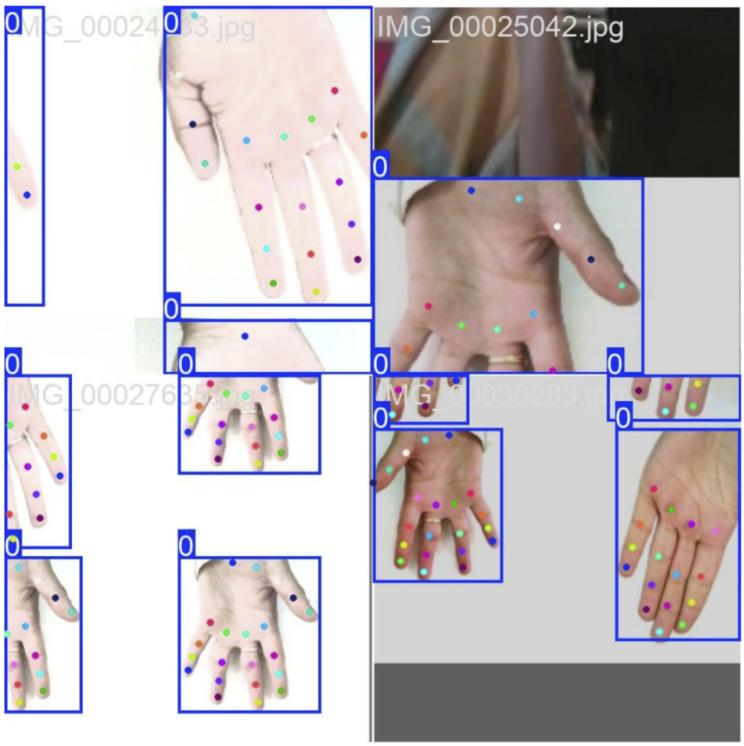

Hình 2.2: Nhận diện các bounding box và các keypoint

2.1. Nhận diện cử chỉ tay dựa trên đặc trưng

Các đặc điểm được tạo thủ công được trích xuất từ hình ảnh cử chỉ bằng cách sử dụng mô hình DSP, FFT, STFT, DWT, các phương pháp dựa trên lọc kernel, . . . , và xem xét ngón tay như một cụm để nhận dạng cử chỉ tay (Ren, Yuan, Zhang, 2011). Ngoài ra, các bộ phân loại dựa trên ML, chẳng hạn như mạng perceptron đa lớp (MLP), mạng nơ-ron trễ thời gian (TDNN), máy vectơ hỗ trợ (SVM), thuật toán K-nearest neighbor (KNN), mô hình Markov ẩn (HMM), máy trạng thái hữu hạn (FSM), rừng ngẫu nhiên (RF), cây quyết định (DT) và bộ phân loại Naïve Bayes, được sử dụng để nhận dạng hoặc phân loại cử chỉ (Kuznetsova, Leal-Taixé, Rosenhahn, 2013; Wang, Wang, Chen, 2013)[15].

Nhận diện cử chỉ tay dựa trên đặc trưng tập trung vào việc biểu diễn hình dạng và tư thế của bàn tay thông qua các đặc trưng phân biệt được trích xuất từ dữ liệu đầu vào. Các đặc trưng này có thể là đặc trưng hình học, kết cấu hoặc đặc trưng không gian phản ánh mối quan hệ giữa các bộ phận của bàn tay, chẳng hạn như vị trí các khớp, hướng và độ mở của các ngón tay. Các phương pháp truyền thống dựa trên đặc trưng thủ công như biên cạnh, contour, mô men, histogram màu da hay template matching giả định hình dạng, kích thước, nền và ánh sáng tương đối ổn định nên thường được thiết kế và tinh chỉnh cho một kịch bản hẹp. Khi đưa ra môi trường thực tế với đa dạng người dùng, bối cảnh, thiết bị và điều kiện chiếu sáng, các đặc trưng này thay đổi mạnh, khó chuẩn hóa và khó khái quát, khiến hệ thống dễ suy giảm độ chính xác và khó mở rộng [14, 15].

2.2. Nhận diện cử chỉ tay dựa trên học sâu

Nhận diện cử chỉ tay là một bài toán thị giác máy tính phức tạp do hình dạng bàn tay có tính biến thiên rất lớn theo tư thế, góc nhìn, kích thước, điều kiện chiếu sáng, nền ảnh và sự che khuất giữa các ngón tay. Các phương pháp xử lý ảnh truyền thống dựa trên đặc trưng thủ công (handcrafted features) như cạnh, contour, histogram hay template matching thường chỉ hoạt động tốt trong những điều kiện kiểm soát chặt chẽ và khó mở rộng sang môi trường thực tế (Sec. II-A).

Mạng nơ-ron, đặc biệt là mạng nơ-ron tích chập (Convolutional Neural Networks – CNN), có khả năng tự động học đặc trưng trực tiếp từ dữ liệu mà không cần thiết kế thủ công. Mạng neuron có khả năng xử lý dữ liệu có chiều cao và không tuyến tính. Mối quan hệ giữa các điểm ảnh trong một cử chỉ tay không đơn giản là tuyến tính, do đó các mô hình tuyến tính hoặc quy tắc cố định khó có thể biểu diễn đầy đủ.

Ngoài ra, mạng neuron cũng cho thấy khả năng tổng quát hóa tốt khi được huấn luyện với dữ liệu đa dạng và các kỹ thuật như data augmentation, batch normalization hay regularization. Điều này giúp mô hình duy trì hiệu suất ổn định khi áp dụng vào dữ liệu mới thu từ camera trong điều kiện thực tế, thay vì chỉ hoạt động tốt trên tập huấn luyện.

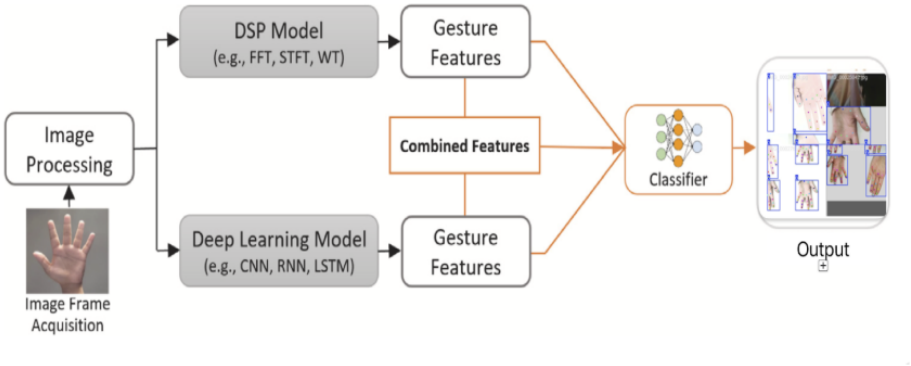

Hình 2.3: Nhận diện cử chỉ tay dựa trên feature và Deep Learning

Chương 3

Mô hình nhận diện cử chỉ tay dựa trên học sâu

Học sâu đã phát triển đa dạng các kiến trúc neuron được thiết kế riêng cho các phương thức dữ liệu và yêu cầu tính toán khác nhau. Các họ chính Mạng Nơ-ron Tích chập (CNN), Mạng Nơ-ron Hồi quy (RNN), Bộ biến đổi (Transformer), Bộ mã hóa Tự động (Autoencoder), Mạng Đối kháng Sinh sinh (GAN), Mô hình Khuếch tán (Diffusion Models) và Mạng Nơ-ron Đồ thị (GNN) đại diện cho các mô hình nền tảng tiếp tục định hình nghiên cứu AI hiện đại.

Convolutional Neural Networks (CNNs) là một trong những nền tảng quan trọng nhất của học sâu hiện đại, đặc biệt trong các bài toán thị giác máy tính. CNN phù hợp với bài toán nhận diện cử chỉ tay vì: (1) dữ liệu đầu vào là ảnh/video dạng lưới, phù hợp với phương pháp xử lý của CNN, (2) nhận diện cử chỉ tay cần dùng backbone CNN để trích xuất đặc trưng không gian, (3) cử chỉ tay là đối tượng có hình dạng và biên rõ, cần phát hiện đúng vị trí, đúng với năng lực của kiến trúc CNN.

CNN được thiết kế với convolution kernel nhỏ quét trên ảnh, rất giỏi trích xuất cạnh, góc, texture và hình dạng cục bộ của bàn tay. Cách biểu diễn này đặc biệt phù hợp với bài toán nhận diện cử chỉ tay, nơi sự khác biệt giữa các lớp thường nằm ở cấu trúc tổng thể và mối quan hệ giữa các ngón tay. CNN backbone trong YOLO tận dụng tính cục bộ (locality) và chia sẻ trọng số (weight sharing) để giảm số lượng tham số và FLOPs so với các mạng fully–connected, do đó việc triển khai trên camera hoặc hệ thống nhúng cho bài toán nhận diện cử chỉ tay là khả thi [9, 10]. Nhận diện cử chỉ tay thường yêu cầu thời gian thực cho các ứng dụng HCI, robot, AR/VR; các mô hình YOLO kết hợp với CNN được thiết kế tối ưu cho tốc độ, có thể chạy trên GPU nhẹ hoặc edge device với FPS cao mà vẫn đảm bảo độ chính xác [8].

Mặc dù Transformer đã trở thành xu hướng trong nhiều lĩnh vực, CNN vẫn cực kỳ hiệu quả trong nhiều tình huống nhờ khả năng trích xuất đặc trưng cục bộ [1]. CNN có inductive bias mạnh về tính cục bộ và dịch chuyển (local receptive field, translation equivariance), giúp mô hình học tốt hơn với lượng dữ liệu ít hơn và ổn định hơn trong quá trình huấn luyện so với nhiều mô hình Transformer thuần túy [4]. Một số nghiên cứu so sánh công bằng (fair comparison) chỉ ra rằng các CNN hiện đại như ConvNeXt có thể đạt độ robust và hiệu năng tương đương, thậm chí vượt trội Transformer trong một số thiết lập nhất định, chứ không hề thua kém toàn diện [2]. Các khảo sát và bài báo gần đây cũng cho thấy không có phương pháp nào thực sự vượt trội hoàn toàn so với phương pháp còn lại: Transformer thường tỏ ra ưu việt trên tập dữ liệu rất lớn và trong việc mô hình hóa quan hệ dài hạn, trong khi CNN vẫn giữ lợi thế khi ưu tiên tốc độ, tài nguyên tính toán và dữ liệu huấn luyện hạn chế [2, 3].

3.1. Một số mạng CNN nâng cao

Trong thực tế huấn luyện mô hình học sâu, các mạng CNN thông thường bộc lộ nhiều hạn chế khi mở rộng độ sâu, đặc biệt là hiện tượng mất gradient và suy giảm hiệu năng huấn luyện (degradation problem), khiến mô hình khó hội tụ dù có khả năng biểu diễn lớn hơn về mặt lý thuyết. Để khắc phục các vấn đề này, nhiều kiến trúc CNN phát triển như ResNet, Inception và DenseNet đã được đề xuất nhằm cải thiện khả năng lan truyền gradient, ổn định quá trình tối ưu và mở rộng không gian biểu diễn đặc trưng.

Cụ thể, các kết nối tắt (skip connections) trong ResNet giúp duy trì đường truyền gradient trực tiếp giữa các tầng, cho phép huấn luyện hiệu quả các mạng rất sâu; Inception khai thác đặc trưng ở nhiều tỉ lệ khác nhau, phù hợp với sự đa dạng kích thước của đối tượng trong ảnh; trong khi DenseNet tăng cường khả năng tái sử dụng đặc trưng và giảm số lượng tham số cần huấn luyện. Nhờ những cải tiến này, các kiến trúc CNN phát triển không chỉ giúp quá trình huấn luyện ổn định hơn mà còn đạt hiệu năng vượt trội so với các CNN thông thường, do đó trở thành lựa chọn phổ biến trong các bài toán thị giác máy tính hiện đại [19].

LeNet và các công trình của Ciresan đã chứng minh CNN rất mạnh cho các bài toán nhận dạng ký tự và đối tượng nhỏ trên các tập dữ liệu đơn giản như MNIST, NORB hay CIFAR–10. Tuy nhiên, các mô hình này còn tương đối nông, kích thước đầu vào nhỏ và không được thiết kế tối ưu cho ảnh RGB phức tạp, nhiều đối tượng, cũng như không có kiến trúc phát hiện một giai đoạn (one–stage detection) như yêu cầu trong bài toán nhận diện cử chỉ tay [5].

AlexNet và VGG là các backbone phân loại thế hệ đầu tiên trên ImageNet với số lượng tham số lớn và chi phí

tính toán cao, đồng thời thiếu nhiều thiết kế hiện đại như batch normalization toàn diện hay các kết nối tắt hiệu quả. Do đó, việc triển khai các mô hình này cho bài toán nhận diện cử chỉ tay thời gian thực trên camera hoặc hệ thống nhúng thường gặp khó khăn về tốc độ [6, 7].

Bài báo ResNet cho thấy các mạng tích chập rất sâu với residual connection có thể được huấn luyện ổn định và đạt độ chính xác cao trên ImageNet, đồng nghĩa với khả năng học các đặc trưng hình dạng và cấu trúc phân cấp hiệu quả cho nhiều loại đối tượng khác nhau [6]. Nhiều kiến trúc phát hiện đối tượng như Faster R–CNN, RetinaNet, Mask R–CNN, SSD cải tiến và các mô hình YOLO–like đã lựa chọn ResNet làm backbone tiêu chuẩn nhờ sự cân bằng tốt giữa độ sâu, độ chính xác và chi phí tính toán, đặc biệt phù hợp với các ảnh RGB độ phân giải vừa phải như khung hình camera chứa bàn tay [8].

EfficientNet đề xuất chiến lược compound scaling, trong đó tăng độ sâu, độ rộng và độ phân giải một cách có nguyên tắc nhằm đạt được độ chính xác cao với số lượng FLOPs và tham số thấp. Điều này giúp EfficientNet trở thành lựa chọn hiệu quả khi triển khai trên các GPU nhỏ, nền tảng Jetson hoặc các thiết bị edge, rất phù hợp với kịch bản camera kết hợp nhận diện cử chỉ tay thời gian thực [6].

Từ những phân tích trên, việc lựa chọn mạng ResNet làm nền tảng xử lý cho bài toán nhận diện cử chỉ tay là hoàn toàn hợp lý. ResNet không chỉ đảm bảo khả năng trích xuất đặc trưng mạnh mẽ và ổn định mà còn dễ dàng tích hợp với các kiến trúc phát hiện đối tượng hiện đại, đáp ứng tốt các yêu cầu về độ chính xác, tốc độ xử lý và khả năng triển khai trong các hệ thống nhận diện cử chỉ tay thời gian thực.

3.2. Trade-off giữa độ sâu của mạng và hiệu suất tính toán

Bên cạnh lợi ích về khả năng biểu diễn, việc tăng độ sâu của mạng nơ-ron cũng kéo theo sự gia tăng đáng kể về chi phí tính toán và tài nguyên hệ thống. Mạng càng sâu thì số lượng phép toán, số tham số và mức tiêu thụ bộ nhớ càng lớn, dẫn đến thời gian huấn luyện và suy luận tăng lên, đồng thời yêu cầu phần cứng mạnh hơn. Mặc dù các kiến trúc CNN phát triển cho phép huấn luyện mạng sâu hiệu quả hơn, độ sâu không phải lúc nào cũng tỷ lệ thuận với hiệu năng mô hình, do lợi ích thu được có thể bão hòa sau một ngưỡng nhất định. Vì vậy, trong thực tế cần cân nhắc trade–off giữa độ sâu của mạng và hiệu suất tính toán, lựa chọn kiến trúc và số tầng phù hợp với bài toán cụ thể nhằm đạt được sự cân bằng giữa độ chính xác và chi phí tính toán [20, 21].

Trong họ kiến trúc ResNet, các mô hình với độ sâu khác nhau được thiết kế nhằm đáp ứng những yêu cầu ứng dụng khác nhau về hiệu suất và chi phí tính toán. ResNet–18, với số lượng tầng và tham số tương đối nhỏ, có độ phức tạp tính toán thấp và thời gian suy luận nhanh, do đó đặc biệt phù hợp với các tác vụ ưu tiên hiệu quả tính toán như phân loại hình ảnh thời gian thực trên các thiết bị nhúng, thiết bị di động hoặc các hệ thống có tài nguyên hạn chế. ResNet–34 cung cấp sự cân bằng giữa độ sâu và hiệu năng, cho phép cải thiện độ chính xác so với ResNet–18 trong khi vẫn duy trì chi phí tính toán ở mức chấp nhận được, phù hợp với các hệ thống yêu cầu hiệu năng trung bình. Trong khi đó, ResNet–50 với kiến trúc sâu hơn và các khối bottleneck có khả năng trích xuất đặc trưng phức tạp, thường được ưu tiên trong các ứng dụng mà việc tối đa hóa độ chính xác là yếu tố then chốt, chẳng hạn như nhận dạng hình ảnh độ phân giải cao, phân tích chi tiết đối tượng hoặc các bài toán thị giác máy tính đòi hỏi mức độ biểu diễn đặc trưng cao, dù phải đánh đổi bằng chi phí tính toán lớn hơn [20, 21].

Chương 4

Dataset

Bộ dữ liệu bao gồm hai thư mục chính `images` và `labels`, cùng với một tệp cấu hình `data.yaml`. Cấu trúc và nội dung của bộ dữ liệu được mô tả chi tiết như sau.

Thư mục images: chứa hai thư mục con là `train` và `val`. Thư mục `train` bao gồm 18 776 tệp ảnh định dạng `.jpg`, trong khi thư mục `val` bao gồm 7 992 tệp ảnh `.jpg`. Mỗi tệp ảnh tương ứng với một hành động của bàn tay, được thu thập và gán nhãn phục vụ cho bài toán nhận diện cử chỉ tay.

Thư mục labels: chứa hai thư mục con là `train` và `val`, tương ứng với các tập dữ liệu huấn luyện và kiểm thử trong thư mục `images`. Thư mục `train` chứa 18 776 tệp `.txt` và thư mục `val` chứa 7 992 tệp `.txt`. Mỗi tệp nhãn lưu trữ thông tin chú thích của hình ảnh tương ứng trong thư mục `images`, bao gồm tổng cộng 51 tham số.

Tham số đầu tiên trong mỗi tệp nhãn là tên lớp (class ID), trong đó giá trị 0 biểu thị lớp *hand*. Do toàn bộ hình ảnh trong bộ dữ liệu đều mô tả các hành động của bàn tay, nên tham số đầu tiên của tất cả các tệp nhãn đều có giá trị bằng 0.

Hai tham số tiếp theo lần lượt là tọa độ trung tâm $(x_{\text{center}}, y_{\text{center}})$ của bounding box, được sử dụng để xác định vị trí của bàn tay trong không gian ảnh. Các tọa độ này đã được chuẩn hóa về khoảng $[0, 1]$ theo kích thước của ảnh đầu vào.

Hai tham số kế tiếp là *width* (chiều rộng) và *height* (chiều cao) của bounding box, mô tả kích thước vùng chứa bàn tay tính từ tọa độ trung tâm. Tương tự, các tham số này cũng đã được chuẩn hóa về khoảng $[0, 1]$.

Mỗi nhóm gồm ba tham số tiếp theo (tổng cộng 21 nhóm) biểu diễn thông tin của một keypoint, bao gồm tọa độ (x, y) và tham số *visibility* (trạng thái nhìn thấy). Trong bộ dữ liệu này, sau khi chuẩn hóa, tồn tại các điểm dữ liệu có giá trị tọa độ x hoặc $y > 1$, điều này cho thấy keypoint tương ứng nằm ngoài phạm vi quan sát của khung hình. Mặc dù vậy, tham số *visibility* vẫn có giá trị bằng 2 ngay cả khi tọa độ keypoint nằm ngoài ảnh, do bộ dữ liệu ưu tiên việc bảo toàn cấu trúc hình học tổng thể của bàn tay hơn là chỉ dựa trên thông tin thị giác cục bộ.

Tệp data.yaml: là tệp cấu hình dữ liệu, dùng để định nghĩa cấu trúc keypoints, nhãn (class names) cũng như các đường dẫn tới tập dữ liệu huấn luyện và kiểm thử. Tệp này đóng vai trò quan trọng trong việc đảm bảo quá trình huấn luyện và đánh giá mô hình được thực hiện đúng theo định dạng và cấu trúc của bộ dữ liệu.

Chương 5

Huấn luyện và đánh giá mô hình

Pipeline huấn luyện mô hình được xây dựng nhằm đảm bảo quá trình học diễn ra có hệ thống, ổn định và có khả năng tổng quát hóa tốt trên dữ liệu thực tế. Pipeline này bao gồm các bước chính: tiền xử lý dữ liệu, chia tập dữ liệu, huấn luyện mô hình, điều chỉnh tham số và đánh giá hiệu suất.

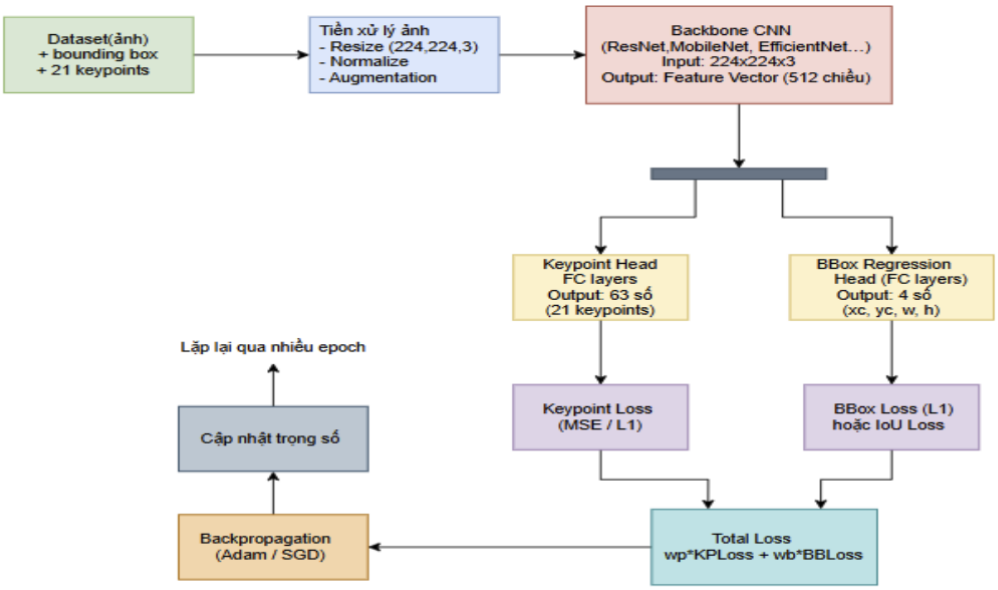

Hình 5.1: Pipeline huấn luyện mô hình nhận diện cử chỉ tay

5.1. Tiền xử lý dữ liệu

Trong các hệ thống thị giác máy tính dựa trên học sâu, chất lượng và định dạng của dữ liệu đầu vào đóng vai trò quyết định đến hiệu suất và khả năng hội tụ của mô hình. Dựa trên các nghiên cứu nền tảng về mạng nơ-ron tích chập và các thực nghiệm liên quan đến nhận diện cử chỉ tay, nhóm nghiên cứu áp dụng quy trình tiền xử lý bao gồm hai giai đoạn chính: chuẩn hóa không gian màu – kích thước và chuẩn hóa phân phối thống kê.

Dữ liệu ảnh thu thập từ các nguồn khác nhau thường có độ phân giải và tỷ lệ khung hình không đồng nhất. Tuy nhiên, kiến trúc mạng ResNet–18 yêu cầu đầu vào phải là các tensor có kích thước cố định để đảm bảo tính nhất quán của các vector đặc trưng trong quá trình tính toán, đi qua các lớp tích chập và lớp kết nối đầy đủ. Trong quá trình triển khai thực nghiệm, hệ thống sử dụng thư viện mã nguồn mở OpenCV để đọc và xử lý ảnh đầu vào. Do đặc thù của thư viện này giải mã hình ảnh dưới định dạng không gian màu BGR, trong khi kiến trúc ResNet–18 yêu cầu định dạng đầu vào là RGB, một bước chuyển đổi không gian màu là bắt buộc để đảm bảo tính tương thích của kênh dữ liệu.

Tiếp theo, hệ thống thực hiện chuẩn hóa kích thước để đưa toàn bộ ảnh về độ phân giải cố định 224×224 pixels [6]. Việc cố định kích thước này giúp giảm thiểu chi phí tính toán và đảm bảo tính nhất quán của tensor đặc trưng đầu vào, một kỹ thuật tiêu chuẩn đã được kiểm chứng hiệu quả trong các nghiên cứu về nhận diện cử chỉ tay thời gian thực [18]. Quá trình này sử dụng thuật toán nội suy song tuyến tính (Bilinear Interpolation) nhằm bảo toàn tốt nhất thông tin biên dạng của bàn tay.

Sau khi thay đổi kích thước, dữ liệu điểm ảnh được chuyển đổi từ miền giá trị nguyên $[0, 255]$ sang miền thực $[0, 1]$ dưới dạng tensor. Để tối ưu hóa quá trình hội tụ của thuật toán Gradient Descent, nhóm nghiên cứu áp dụng kỹ thuật chuẩn hóa Z–score, đưa dữ liệu đầu vào về phân phối chuẩn với giá trị trung bình bằng 0 và phương sai bằng 1, giúp ổn định phân phối dữ liệu đầu vào và tạo điều kiện cho mô hình học đặc trưng hiệu quả hơn [17].

$$z = \frac{x - \mu}{\sigma} \tag{5.1}$$

Các tham số thống kê được thiết lập theo quy chuẩn mặc định của thư viện PyTorch. Cụ thể, vector trung bình $\mu = [0.485, 0.456, 0.406]$ và độ lệch chuẩn $\sigma = [0.229, 0.224, 0.225]$ được áp dụng tương ứng cho ba kênh màu R, G và B. Việc tuân thủ các tham số tiêu chuẩn này giúp đưa dữ liệu đầu vào về trạng thái phân phối lý tưởng (zero–mean, unit–variance), hạn chế hiện tượng bão hòa hàm kích hoạt và hỗ trợ mô hình ResNet–18 tối ưu hóa trọng số một cách ổn định và hiệu quả.

5.2. Huấn luyện mô hình

Mô hình nhận dạng được xây dựng dựa trên nền tảng mạng nơ-ron tích chập (CNN), trong đó hệ thống hoạt động bằng cách sử dụng các bộ lọc trượt trên ảnh đầu vào để trích xuất các mẫu đặc trưng thông qua phép tích chập [6]. Nhóm nghiên cứu lựa chọn kiến trúc ResNet–18 làm mạng xương sống. Việc gia tăng độ sâu mô hình lên các kiến trúc sâu hơn như ResNet–50 đối với ảnh đầu vào có độ phân giải tiêu chuẩn 224×224 không đảm bảo cải thiện tuyến tính về độ chính xác, trong khi làm gia tăng đáng kể thời gian huấn luyện và nguy cơ quá khớp (overfitting) [18]. Do đó, ResNet–18 được lựa chọn như một điểm cân bằng tối ưu giữa khả năng trích xuất đặc trưng sâu và hiệu quả tính toán cho các ứng dụng thời gian thực.

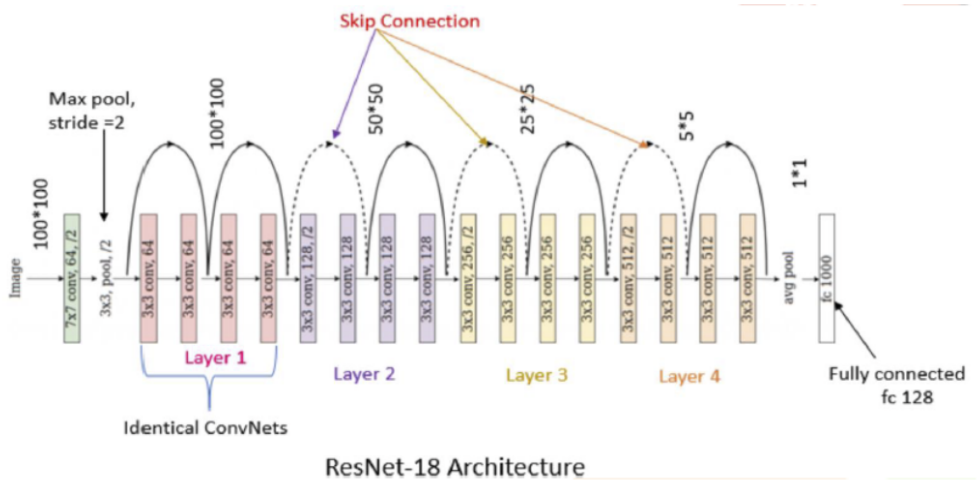

Hình 5.2: Pipeline huấn luyện mô hình nhận diện cử chỉ tay

Về mặt cấu trúc, backbone của mô hình tuân thủ thiết kế chuẩn của ResNet–18 nhằm trích xuất các biểu diễn đặc trưng phân cấp từ ảnh đầu vào. Luồng dữ liệu khởi đầu bằng một lớp tích chập 7×7 với stride bằng 2, kết hợp với lớp Max Pooling để giảm nhanh chiều không gian và giữ lại các đặc trưng sơ cấp quan trọng [6, 38]. Phần thân mạng bao gồm bốn giai đoạn với số lượng bộ lọc tăng dần lần lượt là 64, 128, 256 và 512. Điểm then chốt của kiến trúc này nằm ở cơ chế kết nối tắt (skip connection), cho phép tín hiệu lan truyền trực tiếp qua các lớp theo dạng:

$$y = F(x) + x \tag{5.2}$$

Cơ chế này giải quyết hiệu quả vấn đề vanishing gradient thường gặp ở các mạng CNN truyền thống, đảm bảo khả năng hội tụ ổn định ngay cả khi xây dựng mạng sâu [18, 23, 38].

Để chuyển đổi từ bài toán phân loại sang bài toán hồi quy keypoint, tầng đầu ra của mạng được tái thiết kế hoàn toàn. Thay vì sử dụng các lớp kết nối đầy đủ có số lượng tham số lớn và dễ gây quá khớp, các bản đồ đặc trưng đầu ra kích thước $512 \times 7 \times 7$ được tổng hợp bằng lớp Global Average Pooling (GAP). Phương pháp này nén thông tin không gian của mỗi kênh đặc trưng thành một giá trị đại diện duy nhất, tạo ra vector đặc trưng 512 chiều đồng thời duy trì tính bất biến đối với các dịch chuyển nhỏ của đối tượng [6, 18, 38]. Vector này sau đó được ánh xạ thông qua một lớp tuyến tính duy nhất sang không gian kết quả R^{46}, bao gồm 4 tham số định vị bounding box và 42 tham số tọa độ (x, y) cho 21 keypoints của bàn tay.

Quy trình huấn luyện được xây dựng như một bài toán học giám sát đa nhiệm (Multi–task Learning), trong đó mô hình ResNet–18 đồng thời tối ưu hai mục tiêu: định vị bounding box và dự đoán keypoints. Nhóm nghiên cứu sử dụng hàm mất mát Mean Squared Error (MSE) làm hàm mục tiêu cho bài toán hồi quy, dựa trên các đặc tính

toán học đã được chứng minh trong các nghiên cứu tối ưu hóa mạng nơ-ron sâu [39]. MSE là hàm khả vi tại mọi điểm, cho gradient mượt và ổn định, đồng thời áp dụng hình phạt bậc hai đối với các sai lệch lớn, buộc mô hình ưu tiên điều chỉnh các dự đoán sai lệch nghiêm trọng ngay từ giai đoạn đầu huấn luyện.

Hàm mất mát tổng được xác định như sau:

$$L_{\text{total}} = L_{\text{MSE}}(y_{\text{bbox}}, \hat{y}_{\text{bbox}}) + L_{\text{MSE}}(y_{\text{kp}}, \hat{y}_{\text{kp}}) \tag{5.3}$$

Quá trình tối ưu được thực hiện bằng thuật toán Adam (Adaptive Moment Estimation), với khả năng tự động điều chỉnh tốc độ học cho từng tham số dựa trên các mô-men bậc nhất và bậc hai của gradient, giúp quá trình hội tụ diễn ra nhanh và ổn định [40]. Các tham số huấn luyện được thiết lập với tốc độ học ban đầu 1×10^{-4}, kích thước lô 32 và tổng cộng 30 chu kỳ huấn luyện (epochs) trên nền tảng GPU.

5.3. Đánh giá mô hình

Do độ chính xác phân loại truyền thống không phản ánh đúng hiệu năng trong bài toán định vị tọa độ, nghiên cứu sử dụng chỉ số PCK (Percentage of Correct Keypoints) để đánh giá mô hình [41]. Một keypoint được coi là dự đoán chính xác nếu khoảng cách Euclidean giữa vị trí dự đoán và nhãn thực tế nhỏ hơn một ngưỡng sai số $d_{\text{threshold}}$. Các ngưỡng sai số được khảo sát trong dải từ 0.1% đến 10% so với kích thước không gian ảnh chuẩn hóa, cho phép đánh giá toàn diện khả năng định vị của mô hình ở nhiều mức độ chi tiết khác nhau.

5.4. Kết quả thực nghiệm

Bảng 5.1: Kết quả PCK theo từng ngưỡng sai số

Threshold	Overall	Wrist	Tips	Thumb	Index	Middle	Ring	Pinky
0.10%	0.0007	0.0009	0.0003	0.0006	0.0006	0.0008	0.0006	0.0007
1.20%	0.1161	0.1288	0.0571	0.1037	0.1051	0.1707	0.1077	0.0902
2.30%	0.3763	0.3482	0.2402	0.3302	0.3918	0.5160	0.3788	0.2717
3.40%	0.6246	0.5445	0.4947	0.5536	0.6764	0.7568	0.6504	0.5057
4.50%	0.7761	0.6773	0.6954	0.7140	0.8223	0.8622	0.8044	0.7026
5.60%	0.8534	0.7639	0.8059	0.8092	0.8829	0.9090	0.8764	0.8119
6.70%	0.8950	0.8188	0.8640	0.8631	0.9145	0.9346	0.9131	0.8690
7.80%	0.9197	0.8562	0.8965	0.8949	0.9345	0.9500	0.9349	0.9003
8.90%	0.9371	0.8859	0.9190	0.9171	0.9498	0.9612	0.9485	0.9216
10.00%	0.9486	0.9038	0.9339	0.9329	0.9589	0.9688	0.9584	0.9354

Quá trình huấn luyện diễn ra ổn định trong 30 chu kỳ. Tại ngưỡng sai số trung bình 5.6%, mô hình đạt độ chính xác 85.34%, và khi ngưỡng sai số được nới rộng lên 10%, độ chính xác toàn cục đạt 94.86%. Kết quả này khẳng định khả năng trích xuất đặc trưng hình học mạnh mẽ của mô hình CNN sâu, đáp ứng tốt yêu cầu của các ứng dụng tương tác thời gian thực.

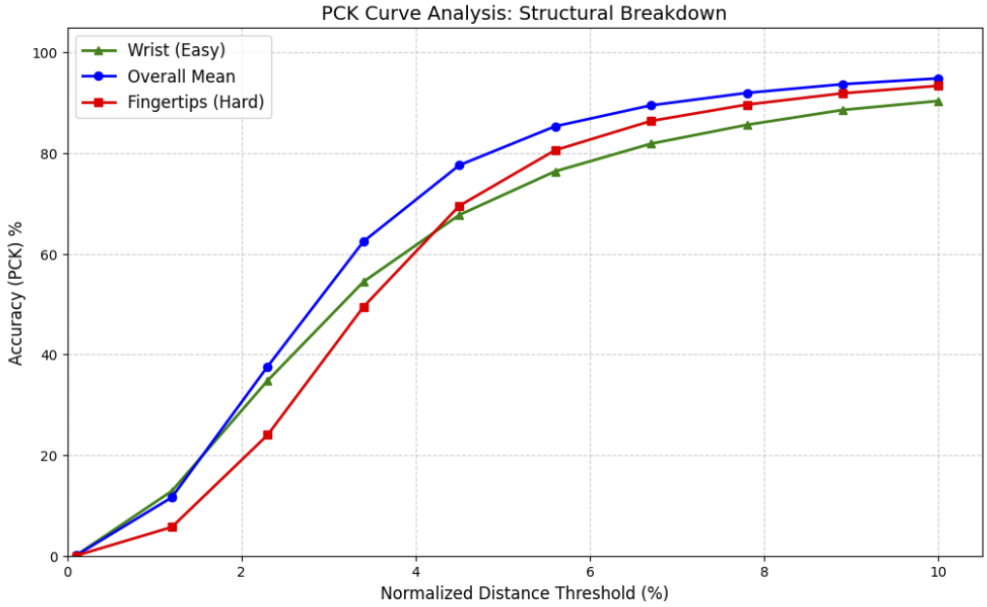

Hình 5.3: PCK Curve Analysis: Structural breakdown

Dựa trên kết quả từ Hình 5.3, có thể rút ra nhận xét rằng mô hình đạt hiệu năng nhận diện rất khả quan với độ chính xác toàn cục (Overall Mean) tỉ lệ thuận với ngưỡng sai số, đạt mức tối đa 94,86% khi ngưỡng sai số được nới rộng lên 10%. Đồ thị cho thấy một sự khác biệt rõ rệt trong đặc trưng thị giác giữa các bộ phận bàn tay: vùng cổ tay (Wrist) dù là điểm gốc nhưng lại có độ chính xác thấp hơn ở các ngưỡng sai số lớn (chỉ đạt 90,38% tại ngưỡng 10%) do thường thiếu các điểm mốc hình học rõ nét và dễ bị che khuất bởi trang phục hoặc phụ kiện. Ngược lại, các đầu ngón tay (Fingertips) tuy khó định vị chính xác ở ngưỡng sai số nhỏ do tư thế biến thiên lớn, nhưng lại đạt độ chính xác vượt trội khi ngưỡng sai số tăng lên nhờ biên dạng rõ nét, tiêu biểu là ngón giữa và ngón trỏ lần lượt đạt tới 96,88% và 95,89%. Điều này khẳng định khả năng trích xuất đặc trưng hình học mạnh mẽ của mạng ResNet-18 , đồng thời chỉ ra rằng việc định vị chính xác điểm gốc cổ tay vẫn là thách thức chính mà các nghiên cứu tiếp theo cần cải thiện thông qua cơ chế Attention hoặc hồi quy bản đồ nhiệt.

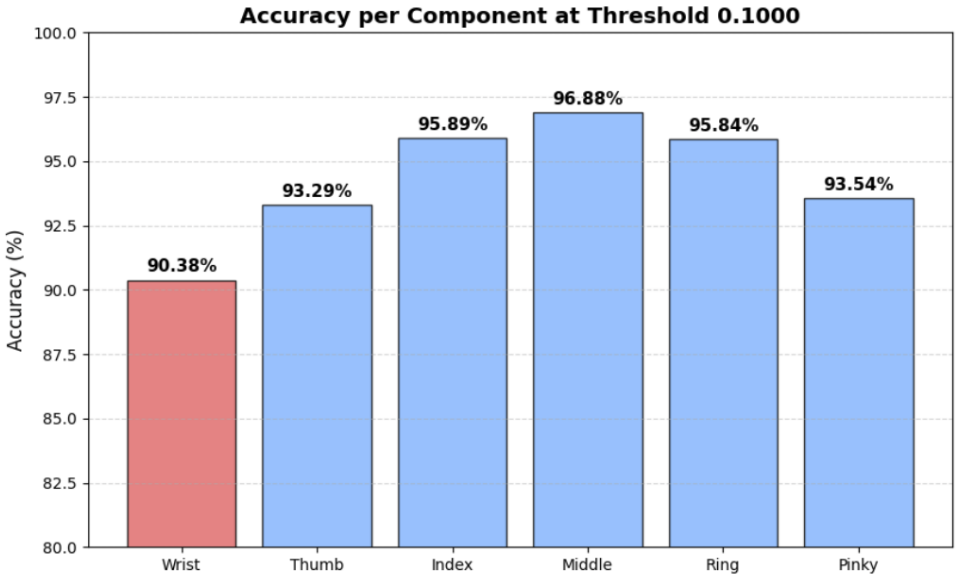

Hình 5.4: Accuracy per component at threshold 0,1000

Kết quả phân tích chi tiết theo từng bộ phận giải phẫu tại Hình 5.4 cho thấy hiệu năng định vị tại các đầu ngón tay vượt trội rõ rệt so với vùng cổ tay. Cụ thể, tại ngưỡng sai số 10%, độ chính xác của ngón giữa và ngón trỏ đạt mức rất cao, lần lượt là 96,88% và 95,89%. Trong khi đó, vùng cổ tay ghi nhận mức độ chính xác thấp nhất hệ thống với 90,38trong khi các đầu ngón tay có biên dạng sắc nét giúp mô hình dễ dàng nhận diện, thì vùng cổ tay thường thiếu các điểm mốc hình học đặc trưng và dễ bị che khuất bởi các yếu tố ngoại cảnh như trang phục hoặc phụ kiện. Điều này dẫn đến sự dịch chuyển nhẹ của khung xương dự đoán và xác định đây là thách thức chính trong việc định vị chính xác keypoints bàn tay.

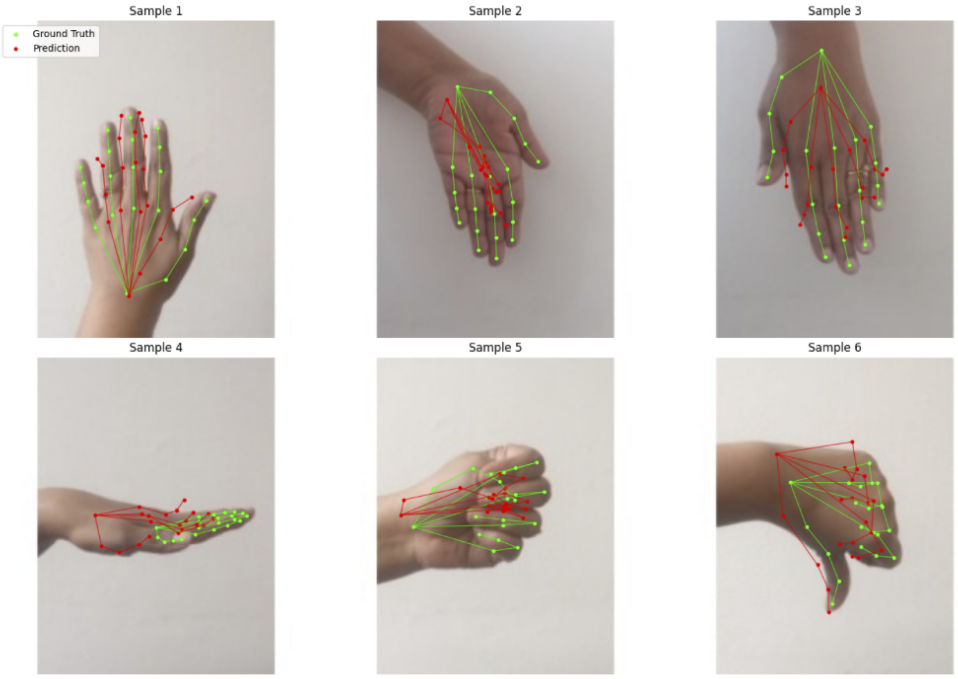

Hình 5.5: Độ lệch key-point so với ground-truth

Thông qua việc đánh giá trực quan trên các mẫu thử nghiệm tại Hình 5.5, có thể thấy mô hình có khả năng tái tạo gần như chính xác cấu trúc hình học của bàn tay trong các cử chỉ phức tạp như nắm hoặc xòe. Tuy nhiên, các sai lệch thực tế chủ yếu xuất phát từ vị trí cổ tay, gây ra hiện tượng dịch chuyển nhẹ của toàn bộ khung xương dự đoán so với thực tế. Điều này một lần nữa khẳng định việc định vị chính xác điểm gốc vẫn là thách thức kỹ thuật lớn nhất của hệ thống hiện tại.

Tổng kết lại, mô hình ResNet-18 đã chứng minh được tính hiệu quả trong việc giải quyết bài toán định vị khớp tay với độ chính xác cao và tốc độ suy luận nhanh, phù hợp cho các ứng dụng thực tế. Để khắc phục những hạn chế còn tồn tại, các nghiên cứu tiếp theo có thể tích hợp thêm cơ chế Attention hoặc chuyển sang phương pháp hồi quy bản đồ nhiệt (Heatmap Regression) nhằm tối ưu hóa độ tin cậy tại các vùng có tính bất định cao như cổ tay.

Mô hình được huấn luyện trong link: https://colab.research.google.com/drive/1bKbL4RlVCwiqp_-xcPA6ieDZzG6-cet3?usp=sharing

Chương 6

Discussion

6.1. So sánh với các nghiên cứu trước đây

So với các phương pháp nhận diện cử chỉ tay truyền thống dựa trên đặc trưng thủ công như biên cạnh, contour, histogram màu da hoặc các mô hình học máy cổ điển như SVM, KNN hay HMM, phương pháp dựa trên học sâu trong nghiên cứu này cho thấy ưu thế rõ rệt về khả năng biểu diễn và tổng quát hóa. Các phương pháp truyền thống thường phụ thuộc mạnh vào các giả định về hình dạng bàn tay, điều kiện ánh sáng và nền ảnh tương đối ổn định, do đó hiệu năng suy giảm đáng kể khi áp dụng vào môi trường thực tế với sự biến thiên lớn về tư thế, góc nhìn và nhiễu nền [29, 30]. Ngoài ra, việc thiết kế đặc trưng thủ công đòi hỏi nhiều kinh nghiệm chuyên môn và khó mở rộng sang các tập dữ liệu mới hoặc các kịch bản ứng dụng khác nhau [31].

Ngược lại, mạng nơ-ron tích chập (CNN) có khả năng tự động học các đặc trưng phân cấp trực tiếp từ dữ liệu ảnh, từ các đặc trưng mức thấp như cạnh và góc đến các biểu diễn hình dạng phức tạp của bàn tay. Cách tiếp cận này đã được chứng minh là hiệu quả trong nhiều bài toán thị giác máy tính và nhận dạng đối tượng [32, 33]. Việc sử dụng backbone ResNet-18 với các kết nối dư (residual connections) giúp cải thiện đáng kể khả năng huấn luyện của mạng sâu, cho phép mô hình học ổn định và trích xuất các đặc trưng hình học của bàn tay một cách hiệu quả ngay cả khi dữ liệu đầu vào có nhiều biến thiên [34].

So với các nghiên cứu gần đây áp dụng các kiến trúc sâu hơn như ResNet-50, EfficientNet hoặc các mô hình dựa trên Transformer cho bài toán nhận dạng cử chỉ tay, mô hình được đề xuất trong báo cáo này đạt được sự cân bằng hợp lý giữa độ chính xác và chi phí tính toán. Các mô hình rất sâu hoặc Transformer-based thường yêu cầu tập dữ liệu quy mô lớn và tài nguyên phần cứng mạnh để đạt hiệu năng cao, đồng thời làm tăng độ trễ suy luận, gây khó khăn cho các ứng dụng thời gian thực [35, 36]. Trong bối cảnh dữ liệu và tài nguyên tính toán hạn chế, ResNet-18 với độ sâu vừa phải cho phép huấn luyện ổn định và duy trì tốc độ suy luận cao. Kết quả này phù hợp với các nghiên cứu chỉ ra rằng CNN với *inductive bias* mạnh về tính cục bộ và bất biến dịch chuyển vẫn là lựa chọn hiệu quả cho các bài toán thị giác máy tính trong điều kiện thực tế [37].

6.2. Đánh giá ưu điểm và hạn chế của mô hình

Ưu điểm nổi bật của mô hình được đề xuất là cấu trúc tương đối đơn giản, dễ triển khai và có hiệu suất tính toán cao. Việc sử dụng ResNet-18 giúp giảm đáng kể số lượng tham số và số phép toán (FLOPs) so với các mạng sâu hơn, từ đó rút ngắn thời gian huấn luyện và suy luận. Cơ chế *residual connection* giúp mô hình hội tụ ổn định, hạn chế hiện tượng mất gradient và cải thiện khả năng học các đặc trưng hình học quan trọng của bàn tay. Ngoài ra, việc kết hợp các kỹ thuật tiền xử lý và chuẩn hóa dữ liệu giúp mô hình đạt khả năng tổng quát hóa tốt khi áp dụng lên dữ liệu mới thu từ camera trong điều kiện thực tế.

Tuy nhiên, mô hình vẫn chưa khai thác được các ràng buộc hình học giữa bounding box và tập keypoints. Bên cạnh đó, do cấu trúc bàn tay có nhiều khớp nhỏ và các ngón tay thường chồng lấn, mô hình gặp khó khăn trong các trường hợp các ngón tay che khuất lẫn nhau, bàn tay cầm vật hoặc một phần bàn tay nằm ngoài khung hình. Điều này đặc biệt ảnh hưởng đến độ chính xác của các keypoints ở đầu ngón tay. Các yếu tố môi trường như ánh sáng yếu hoặc không đồng đều, nhiễu nền phức tạp, màu da gần với màu nền vẫn là thách thức đối với cả bài toán phát hiện bounding box và định vị keypoints. Ngoài ra, do mỗi khung hình được xử lý độc lập, vị trí các keypoints có thể dao động nhẹ giữa các frame liên tiếp, ngay cả khi bàn tay gần như đứng yên. Hiện tượng này có thể ảnh hưởng đến các ứng dụng yêu cầu độ ổn định cao của hình dạng bàn tay theo thời gian.

6.3. Khả năng ứng dụng thực tiễn

Với sự cân bằng hợp lý giữa độ chính xác và hiệu suất tính toán, mô hình nhận diện cử chỉ tay được đề xuất cho thấy tiềm năng ứng dụng cao trong nhiều lĩnh vực thực tế. Trong các hệ thống tương tác người–máy (HCI), mô hình có thể được triển khai để điều khiển thiết bị thông minh, xây dựng giao diện không chạm hoặc hỗ trợ các hệ thống trình chiếu và giải trí. Trong lĩnh vực robot và tự động hóa, nhận diện cử chỉ tay thời gian thực cho phép người dùng giao tiếp và điều khiển robot một cách trực quan và an toàn hơn.

Ngoài ra, mô hình cũng phù hợp cho các ứng dụng hỗ trợ người khuyết tật hoặc người khiếm thính thông qua việc nhận dạng cử chỉ tay như một hình thức giao tiếp thay thế. Nhờ chi phí tính toán thấp, hệ thống có thể được triển khai trên các thiết bị nhúng, các nền tảng *edge device* hoặc camera thông minh, mở ra khả năng ứng dụng trong các môi trường công nghiệp, y tế và nhà thông minh. Trong tương lai, việc mở rộng mô hình theo hướng tích hợp thông tin thời gian (video-based) hoặc kết hợp với các kiến trúc tiên tiến hơn có thể tiếp tục nâng cao độ chính xác và phạm vi ứng dụng của hệ thống.

Tài liệu tham khảo

[1] FlyPix AI, "Image recognition models: CNNs," [Online]. Available: https://flypix.ai/image-recognition-models-cnns/.

[2] A. Trockman and J. Z. Kolter, "Patches are all you need?," arXiv preprint arXiv:2111.05464, 2021. [Online]. Available: https://arxiv.org/pdf/2111.05464.

[3] Towards Data Science, "Vision transformers (ViT) explained: Are they better than CNNs?," [Online]. Available: https://towardsdatascience.com/vision-transformers-vit-explained-are-they-better-than-cnns/.

[4] Roboflow, "Vision transformer vs CNN for detection," [Online]. Available: https://blog.roboflow.com/vision-transformer-vs-cnn-for-detection/.

[5] D. C. Ciresan, U. Meier, J. Masci, and J. Schmidhuber, "Flexible, high performance convolutional neural networks for image classification," arXiv preprint arXiv:1102.0183, 2011. [Online]. Available: https://arxiv.org/abs/1102.0183.

[6] LearnOpenCV, "Understanding convolutional neural networks (CNNs)," [Online]. Available: https://learnopencv.com/understanding-convolutional-neural-networks-cnn/.

[7] Encord, "Convolutional neural networks explained," [Online]. Available: https://encord.com/blog/convolutional-neural-networks-explained/.

[8] Viso.ai, "Image classification in computer vision," [Online]. Available: https://viso.ai/computer-vision/image-classification/.

[9] ScienceDirect Topics, "Convolution layer," [Online]. Available: https://www.sciencedirect.com/topics/computer-science/convolution-layer.

[10] Towards Data Science, "Translational invariance vs translational equivariance," [Online]. Available: https://towardsdatascience.com/translational-invariance-vs-translational-equivariance-f9fb

[11] Y. et al., "Hand gesture recognition: A survey," arXiv preprint arXiv:2405.16264, 2024. [Online]. Available: https://arxiv.org/pdf/2405.16264v1.

[12] A. K. et al., "Hand gesture recognition for human–computer interaction," *Sensors*, 2021. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC8321080/.

[13] CEUR Workshop Proceedings, "Hand gesture recognition systems," [Online]. Available: https://ceur-ws.org/Vol-3398/p08.pdf.

[14] X. et al., "A comprehensive review on hand gesture recognition," arXiv preprint arXiv:2501.11992, 2025. [Online]. Available: https://arxiv.org/pdf/2501.11992.

[15] ScienceDirect, "Hand gesture recognition methods and datasets," [Online]. Available: https://pdf.sciencedirectassets.com/271506.

[16] PeerJ Computer Science, "Deep learning-based hand gesture recognition," [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC7924500/pdf/peerj-cs-05-218.pdf.

[17] H. et al., "A review of deep learning-based gesture recognition," *Machine Learning and Knowledge Extraction*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2307187724000452.

[18] ACM, "Real-time hand gesture recognition," [Online]. Available: https://dl.acm.org/doi/epdf/10.1145/3704137.

[19] Preprints, "Recent advances in CNN architectures," [Online]. Available: https://www.preprints.org/manuscript/202510.1050.

[20] M. Sandler et al., "MobileNetV2: Inverted residuals and linear bottlenecks," arXiv preprint arXiv:1610.02357, 2016. [Online]. Available: https://arxiv.org/pdf/1610.02357.

[21] IEEE, "Efficient deep CNN architectures," IEEE Trans. Image Process., 2017. [Online]. Available: https://ieeexplore.ieee.org/document/7780459.

[22] Springer, "Deep learning models for computer vision," [Online]. Available: https://link.springer.com/article/10.1186/s40537-021-00444-8.

[23] AI Candy, "Mô hình ResNet: Đột phá trong nhận diện hình ảnh," [Online]. Available: https://aicandy.vn/mo-hinh-resnet-dot-pha-trong-nhan-dien-hinh-anh/.

[24] Sensors, "Vision-based hand keypoint detection," [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC7071082/pdf/sensors-20-01074.pdf.

[25] University of Hertfordshire, "Hand pose estimation methods," [Online]. Available: https://uhra.herts.ac.uk/id/eprint/25619/1/paper_17.pdf.

[26] LearnOpenCV, "Hand keypoint detection using deep learning and OpenCV," [Online]. Available: https://learnopencv.com/hand-keypoint-detection-using-deep-learning-and-opencv/.

[27] Kaggle, "ResNet-based prediction example," [Online]. Available: https://www.kaggle.com/code/keremdokumaci/brain-tumor-prediction-w-resnet-in-pytorch.

[28] Taylor & Francis, "Gesture recognition techniques," [Online]. Available: https://www.tandfonline.com/doi/epdf/10.1080/22797254.2021.1880975.

[29] Z. Ren, J. Yuan, and Z. Zhang, "Robust hand gesture recognition based on finger-earth mover's distance," in *Proc. ACM Multimedia*, 2011. [Online]. Available: https://3dvar.com/Ren2011Robust.pdf.

[30] A. Kuznetsova, L. Leal-Taixé, and B. Rosenhahn, "Real-time sign language recognition," in *Proc. ICCV Workshops*, 2013. [Online]. Available: https://openaccess.thecvf.com/content_iccv_workshops_2013/W02/papers/Kuznetsova_Real-Time_Sign_Language_2013_ICCV_paper.pdf.

[31] R. Wang, S. Wang, and X. Chen, "Hand gesture recognition systems: A review," in *Proc. ICIP*, 2013. [Online]. Available: https://www.researchgate.net/publication/391628627_Hand_Gesture_Recognition_Systems_A_Review_of_Methods_Datasets_and_Emerging_Trends.

[32] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998. [Online]. Available: http://vision.stanford.edu/cs598_spring07/papers/Lecun98.pdf.

[33] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436–444, 2015. [Online]. Available: https://www.nature.com/articles/nature14539.

[34] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. CVPR*, 2016. [Online]. Available: https://arxiv.org/abs/1512.03385.

[35] A. Dosovitskiy et al., "An image is worth 16×16 words: Transformers for image recognition at scale," in *Proc. ICLR*, 2021. [Online]. Available: https://arxiv.org/abs/2010.11929.

[36] H. Touvron et al., "Training data-efficient image transformers & distillation through attention," in *Proc. ICML*, 2021. [Online]. Available: https://arxiv.org/abs/2012.12877.

[37] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. [Online]. Available: https://aikosh.indiaai.gov.in/static/Deep+Learning+Ian+Goodfellow.pdf.

[38] ResearchGate, "ResNet-18 model architecture," [Online]. Available: https://www.researchgate.net/publication/364345322.

[39] Y. et al., "Loss functions for regression in deep learning," arXiv preprint arXiv:2307.02694, 2023. [Online]. Available: https://arxiv.org/abs/2307.02694.

[40] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," arXiv preprint arXiv:1412.6980, 2014. [Online]. Available: https://arxiv.org/abs/1412.6980.

[41] Y. Yang and D. Ramanan, "Articulated pose estimation with flexible mixtures of parts," *IEEE TPAMI*, 2013. [Online]. Available: https://www.cs.cmu.edu/~deva/papers/pose_pami.pdf.